Universidade Federal do ABC

Aula 02 - PSO

- Meta-heurísticas

Particle Swarm Optimization (PSO)

Prof. Dr. Edmarcio Antonio Belati

edmarcio.belati@ufabc.edu.br

2023.1

Meta-Heurísticas

Algoritmo

META-HEURÍSTICAS

Definição (meta-heurística):

Segundo *Luke (2009)* a área que estuda as meta-heurísticas é considerada um subcampo da área de otimização estocástica.

Otimização estocástica: classe geral de algoritmos e técnicas que empregam algum grau de aleatoriedade para encontrar soluções tão ótimas quanto possível para problemas reconhecidamente difíceis .

Segundo *Glover e Kochenberger (2003)* meta-heurísticas são métodos de solução que coordenam procedimentos de busca (heurísticas), de modo a criar um processo capaz de escapar de mínimos locais e realizar uma busca robusta no espaço de soluções de um problema.

LUKE, S. (2009). Essentials of Metaheuristics. Disponível em http://cs.gmu.edu/~sean/book/ metaheuristics/

GLOVER, F. e KOCHENBERGER, G. A. (2003). Handbook of Metaheuristics. Kluwer Academic Publishers, Boston.

META-HEURÍSTICAS

Uma meta-heurística, visa produzir um resultado satisfatório para um problema, porém sem qualquer garantia de otimalidade.

Assim, as meta-heurísticas são indicadas para:

- Encontrar respostas a problemas sobre os quais há poucas informações;

- Resolver problemas em que as técnicas convencionais que utilizam derivadas não podem ser aplicas devido ao espaço de solução ser muito grande ou apresentar alguma particularidade.

Porém, dada uma solução candidata ao problema, esta pode ser testada e sua otimalidade averiguada.

Alguns exemplos de meta-heurísticas:

- ✓Tabu Search
- ✓Simulated Annealing
- ✓**Particle Swarm Optimization (PSO)**
- ✓Firefly Algorithm
- ✓Bat Algorithm
- ✓Ant Colony Optimization
- ✓**Genetic Algorithms (GA)**
- ✓**Flower Pollination Algorithm (FPA)**
- ✓**Symbiotic Organisms Search (SOS)**
- ✓Grey Wolf Optimizer (trabalho)

Meta-heurísticas Populacionais

Segundo *Sucupira (2007)* as meta-heurísticas populacionais utilizam uma população que evolui através da interação entre seus indivíduos e de processos individuais, na busca de uma solução. O processo objetiva aumentar a qualidade média das soluções individuais na tentativa de obter a ótima sem comprometer a diversidade do conjunto.

SUCUPIRA, Igor Ribeiro, Dissertação de Mestrado: Um Estudo Empírico de Hiper-Heurísticas. IME/USP, 2007.

Meta-heurísticas Bio-inspiradas

São formuladas inspirados em fenômenos da natureza.

META-HEURÍSTICAS POPULACIONAIS

- Funcionam tanto com parâmetros contínuos como discretos ou uma combinação deles.

- Realizam buscas simultâneas em várias regiões do espaço de busca, pois trabalham com uma população e não com um único ponto.

- Utilizam informações de custo ou recompensa e não derivadas ou outro conhecimento auxiliar.

- Não é necessário conhecimento matemático aprofundado do problema tratado.

META-HEURÍSTICAS POPULACIONAIS

- Otimizam um número grande de variáveis.

- Otimizam parâmetros de funções objetivos com superfícies complexas e complicadas, reduzindo a incidência de mínimos locais.

- Adaptam-se bem em computação paralela.

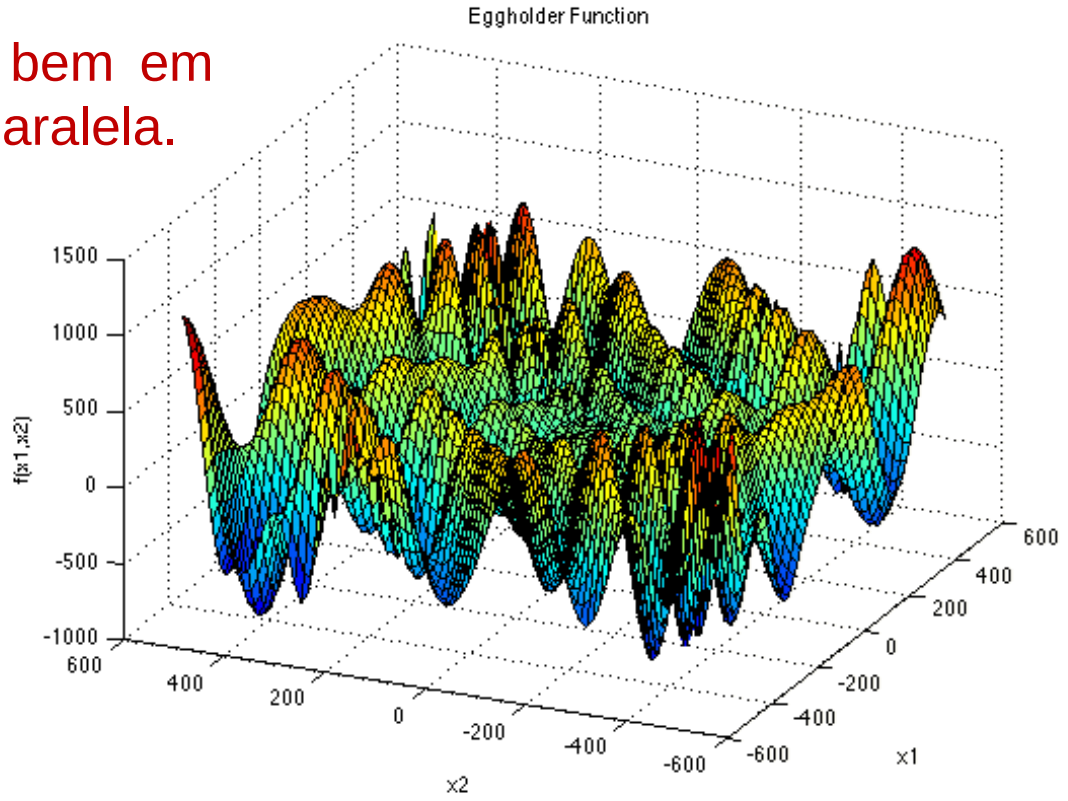

INTELIGÊNCIA DE ENXAMES

- As propriedades principais de um sistema de inteligência de enxame são (Millonas, 1994):
  - *Proximidade* - os agentes devem ser capazes de interagir;
  - *Qualidade* - os agentes devem ser capazes de avaliar seus comportamentos;
  - *Diversidade* - permite ao sistema reagir a situações inesperadas;
  - *Estabilidade* - nem todas as variações ambientais devem afetar o comportamento de um agente;
  - *Adaptabilidade* - capacidade de adequação a variações ambientais.

Millonas, M. M. (1994). Swarms, phase transitions, and collective intelligence. In C.G. Langton (Ed.), Artificial Life III, pp. 417-445. Reading, MA: Addison-Wesley

Particle Swarm Optimization

Algoritmo

Otimização por Enxame de Partículas (PSO)

Edmarcio Belati

O algoritmo Otimização por Enxame de Partículas (PSO), foi originalmente desenvolvido pelos pesquisadores Dr. Kennedy e Dr. Eberhart em 1995 com base no comportamento social de cardumes de peixes e bandos de pássaros.

Figura 2. cardume de peixes

Figura 3. bando de pássaros

Evolução do PSO - Publicações

Edmarcio Belati

IEEE Xplore®

https://ieeexplore.ieee.org/

Publicações somente no IEEE Xplorer usando a palavrar "*particle swarm optimization*".

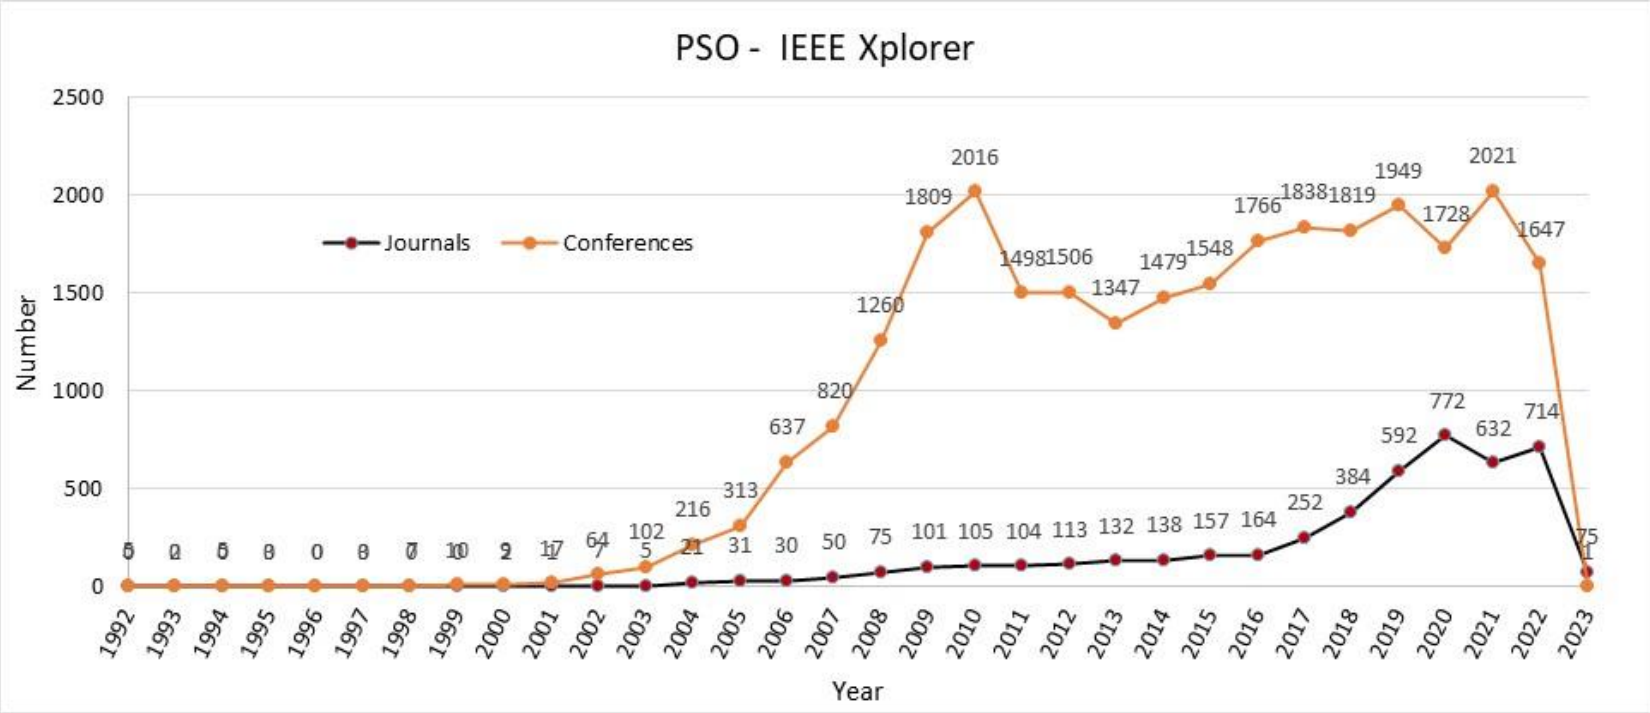

Otimização por Enxame de Partículas (PSO)

O PSO encontra-se, atualmente, entre as meta-heurísticas baseadas em padrões da natureza mais populares, sendo um algoritmo promissor para a resolução de diversos problemas de otimização, quer na área das ciências, quer das engenharias.

Desde a sua criação, já foram desenvolvidas muitas variantes para a resolução de problemas práticos relativos à otimização.

O PSO é inspirado no comportamento social e cooperativo exibido por várias espécies, de forma a realizar as suas necessidades no espaço de pesquisa (“*search-space”)*

O PSO realiza poucas ou nenhumas premissas sobre o problema que está a ser otimizado e pode procurar soluções candidatas em espaços de grandes dimensões.

Otimização por Enxame de Partículas (PSO)

O PSO, como as demais meta-heurísticas, não garante que uma solução ótima seja encontrada.

Em termos gerais, o algoritmo guia-se por experiência pessoal (P_{best}), experiência geral (G_{best}) e o movimento das partículas (velocidade) para decidir as posições seguintes no espaço de busca.

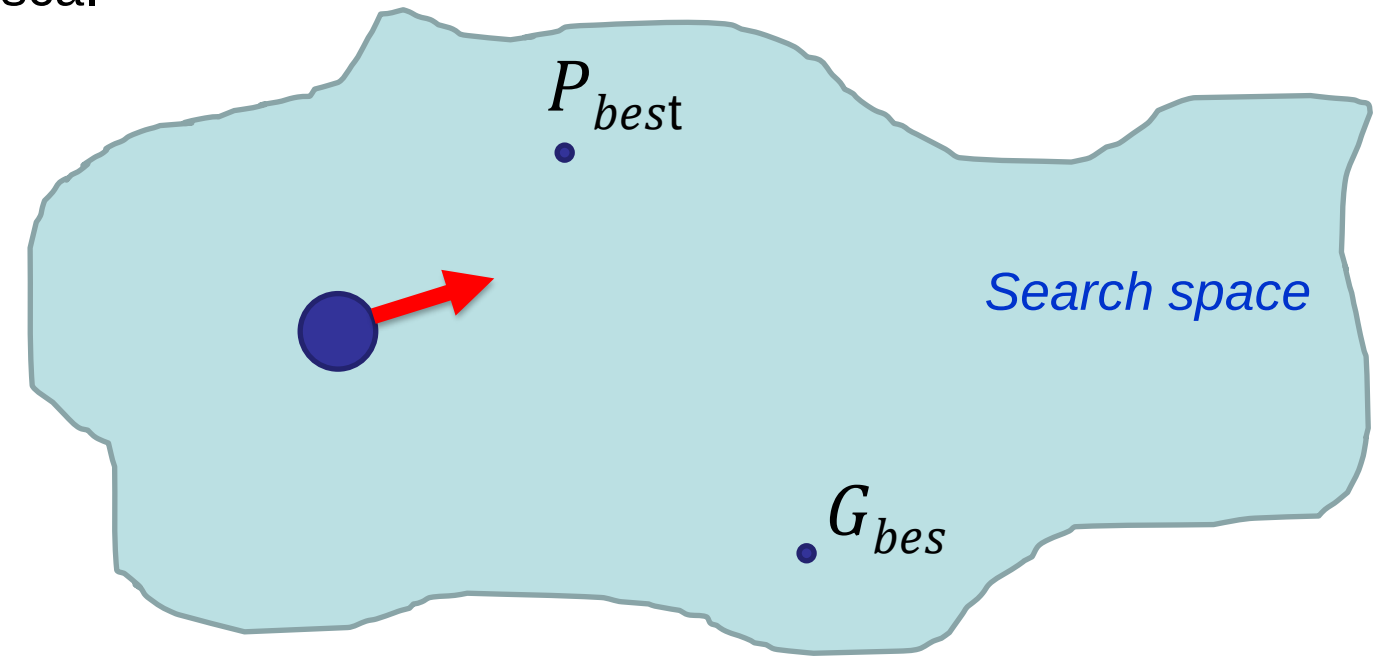

Otimização por Enxame de Partículas (PSO)

O PSO é baseado no princípio de que cada indivíduo pode mudar a sua opinião (ou estado) de acordo com três fatores:

1. Conhecimento do entorno.

   (Memória da partícula)

2. Os estados pelos quais ela passou.

   (Fator cognitivo)

3. Os estados pelos quais tem passado os indivíduos próximos.

   (Fator social)

Conceitos do PSO

- Uma população de soluções é mantida.
  - Número de partículas constantes
- Cada indivíduo da população (partícula) é um vetor de reais que corresponde a uma possível solução.

$$x_i = [x_{i1} + x_{i2} + \cdots + x_{in}]$$

- Cada elemento da partícula possui uma posição e uma velocidade no $\Re^n$.

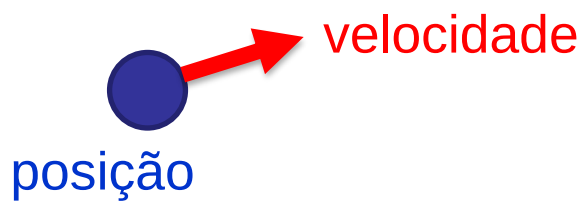

Otimização por Enxame de Partículas (PSO)

Edmarcio Belati

- O processo de atualização de cada elemento de uma partícula possui dois componentes:

  a) Melhor experiência (posição visitada) pessoal - P_{bes};

  b) Melhor experiência (posição visitada) do grupo - G_{best}.

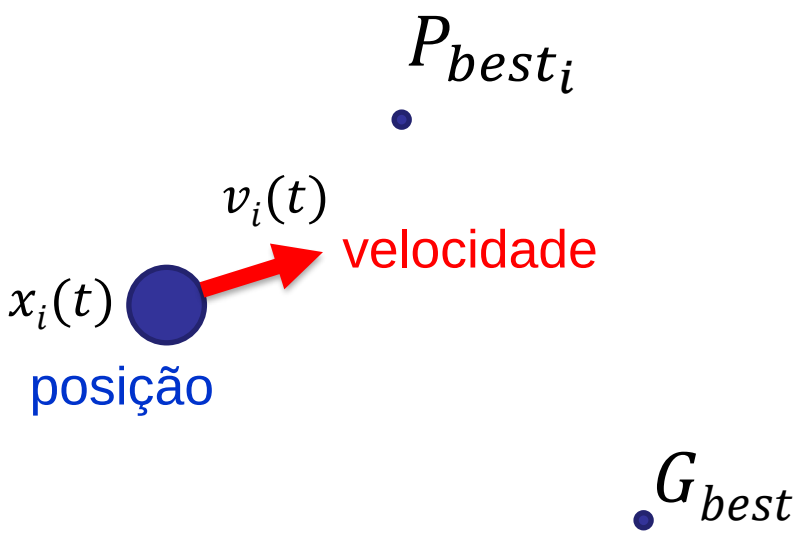

Otimização por Enxame de Partículas (PSO)

- $x_i(t)$: vetor posição atual (iteração *t*) da partícula i.
- $v_i(t)$: vetor velocidade atual da partícula i, pode ser visto como um Δx. Está limitada por $[v_{min}, v_{max}]$.
- P_{best_i}: vetor com a melhor posição visitada pela partícula i.
- G_{best}: melhor entre as melhores posições visitadas pelo grupo.
- A avaliação das posições de cada partícula é feita pela função de desempenho (*fitness*) a qual se deseja otimizar.
  - Em cada iteração tem uma solução candidata para cada partícula.

- Passos do PSO

1 - inicializar população de partículas

- Atribuir de forma randômica uma posição (x_i) e uma velocidade (v_i) para cada elemento de cada partícula dentro de espaço de busca.

- Avaliar cada partícula (*fitness*) atribuindo a solução com a P_{best} e encontrar a melhor de todas, a G_{best}.

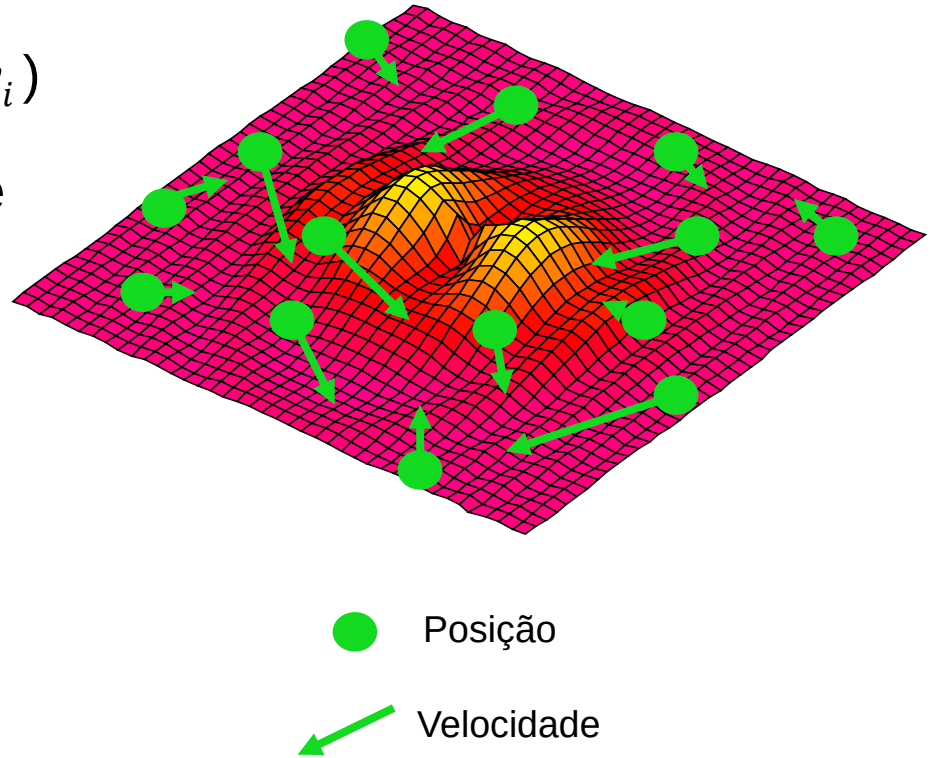

2. Atualização das posições e parâmetros

$$v_i(t+1) = \omega v_i(t) + c_1 r_1 (P_{best_i}(t) - x_i(t)) + c_2 r_2 (G_{best} - x_i(t))$$

$$x_i(t+1) = x_i(t) + v_i(t+1)$$

- ω é o peso de inércia (momento). Existem várias propostas de peso de inércia na literatura; Maior inércia = explora uma região maior. Menor inércia = exploração uma região menor.
- r_1 e r_2 são ambas variáveis aleatórias contidas entre [0;1]. Representam o componente estocástico do algoritmo; Alteram em cada iteração.
- c_1 e c_2 são os coeficientes de aceleração pessoal e global, contido muitas vezes entre [0;2]. Influenciam no tamanho máximo do passo que uma partícula pode dar em uma iteração.

Otimização por Enxame de Partículas (PSO)

- Movimentação das partículas
  - O vetor velocidade $v_i(t)$ de cada partícula i sofre a ação do ótimo individual e do ótimo global. Para melhorar a convergência a velocidade de cada partícula é limitada em um intervalor $[-v_{min}, v_{max}]$. Para evitar a saturação da função é recomendado limitar a velocidade. As referências indicam valores próximos ao intervalo [-4; 4].

Geralmente as partículas superam o ponto de ótimo atual a partir de várias direções explorando regiões promissoras.

Todas as partículas possuem a chance de descobrir um ótimo global e compartilhar com as demais.

Otimização por Enxame de Partículas (PSO)

Edmarcio Belati

Partículas ajustam suas posições de acordo com um "comprometimento psicossocial" entre o que um indivíduo se sente confortável, e o que a sociedade considera.

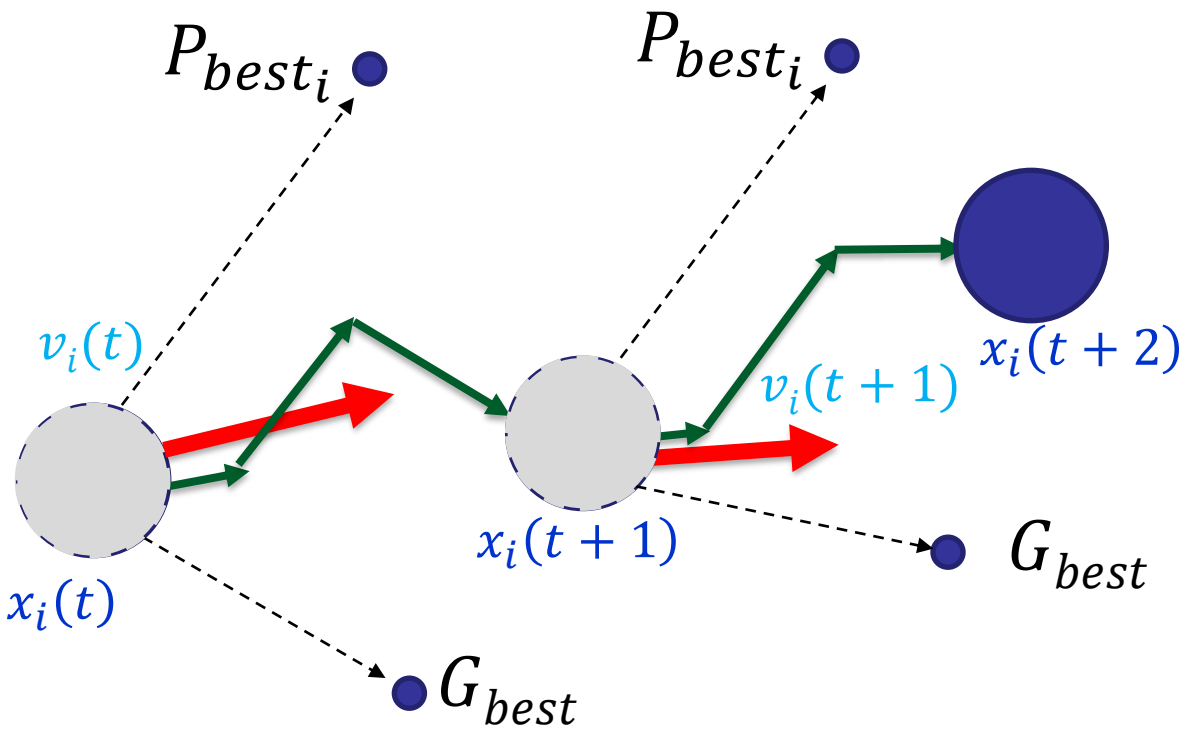

$$v_i(t+1) = \omega v_i(t) + c_1 r_1 (P_{best_i}(\mathrm{t}) - x_i(t)) + c_2 r_2 (G_{best} - x_i(t))$$

$$x_i(t+1) = x_i(t) + v_i(t+1)$$

3 - Após o movimento das partículas obter os novos valores de P_{best} e G_{best}

Para problemas de minimizar

- para cada partícula i da população faça

se $f(xi(t)) < f(P_{best_i}(t))$ então $P_{best_i}(t) = xi(t)$

se $f(P_{best_i}(t)) < f(G_{best})$ então $G_{best} = P_{best_i}(t)$

4 – Se o critério de parada não for satisfeito, voltar ao passo 2, caso contrário fim.

Peso de Inércia (w)

- **Peso de Inércia (w)**
  - Não era utilizado originalmente, mas se tornou padrão.
  - Controla o grau de convergência da busca
  - Pode ser fixo, decrescente ou utilizar outra estratégia.

Estudar os artigos

Sameh Kessentini and Dominique Barchiesi - Particle Swarm Optimization with Adaptive Inertia Weight - International Journal of Machine Learning and Computing, Vol. 5, No. 5, October 2015.

Bansal, J.C., Singh, P.K., Saraswat, M., Verma, A., Jadon, S.S., & Abraham, A. 2011. Inertia Weight strategies in Particle Swarm Optimization. 2011 Third World Congress on Nature and Biologically Inspired Computing, 633-640.

Peso de Inércia (w)

Edmarcio Belati

1	Constante	$\omega = 0,7$	(SHI; EBERHART, 1998)

SHI, Y.; EBERHART, R. C. Parameter Selection in Particle Swarm Optimization. **Annual Conference on Evolutionary Programming**, v. 1447, p. 591–600, 1998.

2	Randômico	$\omega = 0,5 + \frac{rand}{2}$	(EBERHART; SHI, 2001)

EBERHART, R. C.; SHI, Y. **Tracking and optimizing dynamic systems with particle swarms**. Congress on Evolutionary Computation. **Anais**...Seoul: IEEE, 2001

3	Decréscimo linear	$\omega(t) = \omega_{max} - \frac{\omega_{max} - \omega_{min}}{t_{máx}} * t$	(SHI; EBERHART, 1999)

SHI, Y.; EBERHART, R. C. Empirical Study of Particle Swarm Optimization. **Proceedings of the 1999 Congress on Evolutionary Computation, CEC 1999**, v. 3, p. 1945–1950, 1999.

4	Acréscimo Sigmoidal	$\omega(t) = \frac{\omega_{start} - \omega_{end}}{1 + e^{u*(t-n*t_{max})}} + \omega_{end}$ $u = 10^{log(t_{max})-2}$	(MALIK et al., 2007)

MALIK, R. F. et al. New Particle Swarm Optimizer with Sigmoid Increasing Inertia Weight. **International Journal of Computer Science and Security**, v. 1, n. 2, p. 35–44, 2007.

Aplicação – PSO (parâmetros)

Edmarcio Belati

$$\omega(t) = \omega_{max} - \frac{\omega_{max} - \omega_{min}}{t_{máx}} * t$$

(SHI; EBERHART, 1999)

```
I_max=100;          % Maximum iteration
M=100;               % Number of Particle


W_max=0.9;          % Maximum weight              - PSO
W_min=0.4;          % Minimum weight              - PSO

c1=1.0;             % Learning factor 1           - PSO
c2=1.5;             % Golbal Learning factor 2 - PSO


V_max= (X_max- X_min)/10;   % Boundary      - PSO
V_min= -(X_max- X_min)/10 ; % Boundary      - PSO
```

Mais detalhes nos códigos disponibilizados.

Parâmetros do PSO

Edmarcio Belati

Como escolher os parâmetros?

- Número de partículas (10-100) e número de iterções (50-150), geralmente são suficientes.
- Normalmente $C_1 + C_2 = 2{,}5$ é uma boa escolha. Nenhuma boa razão além do empirismo.
- Intervalo de v_{max} e v_{min} muito pequeno, convergêncai lenta; muito grande, convergência instável. Os limites têm que estarem de acordo com o espaçõ de busca. Pode ser $(X_{min}/5; X_{max}/5)$ - nada além do empirismo.

Critérios de Parada do PSO

Edmarcio Belati

Quando finalizar o processo iterativo?

1

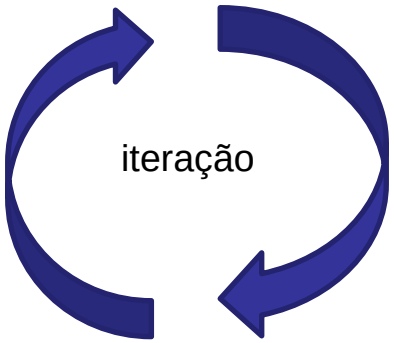

Número máximo de iterações

2

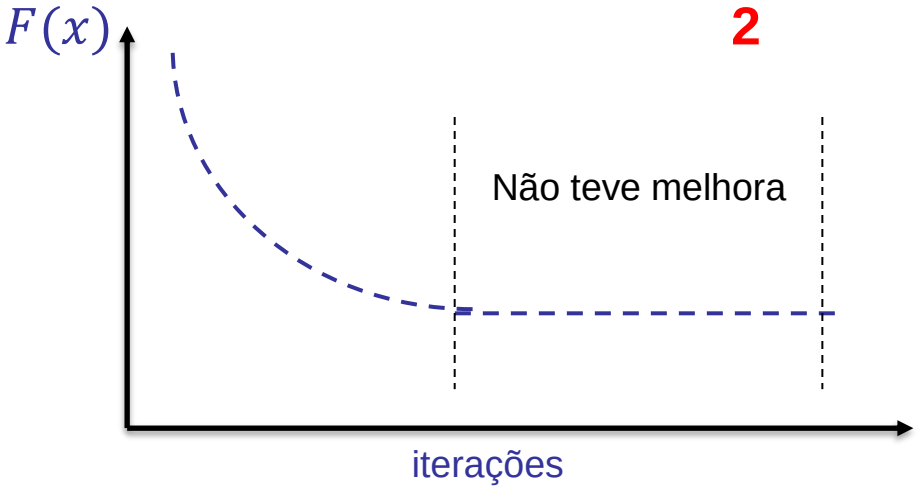

Estagnação

3

Outro critério, dependendo do problema.

Fluxograma Básico do PSO

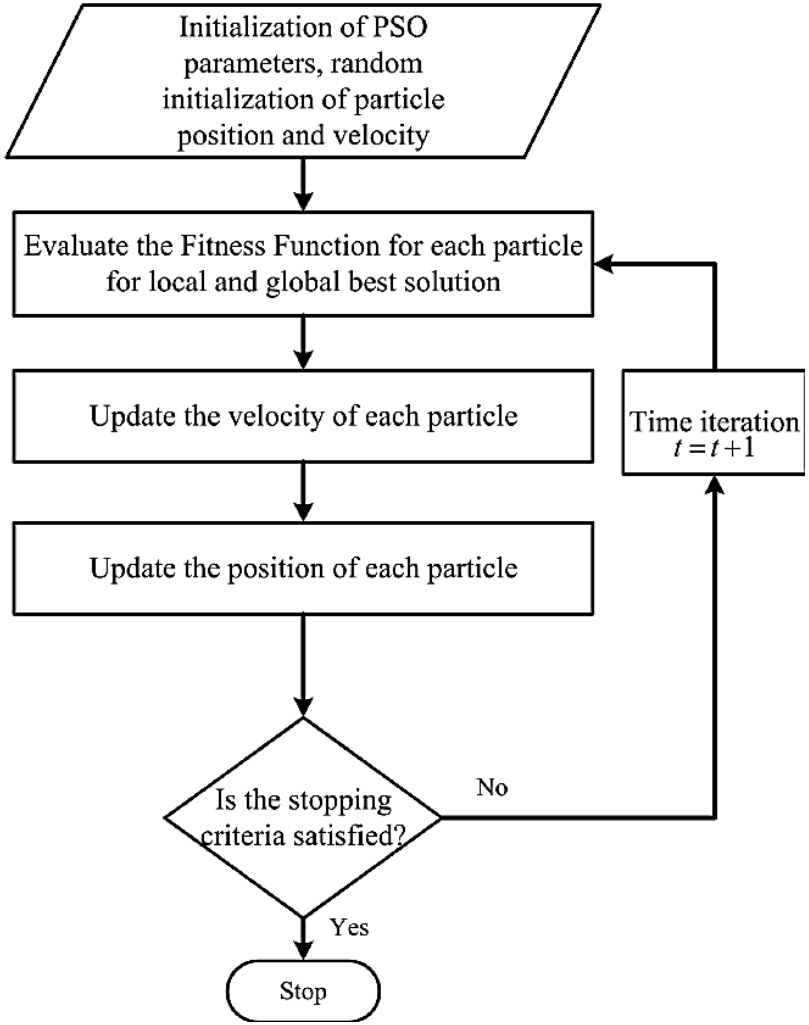

Flowchart-for-basic-PSO-algorithm.png (658×837) (researchgate.net)

Exemplo PSO

Edmarcio Belati

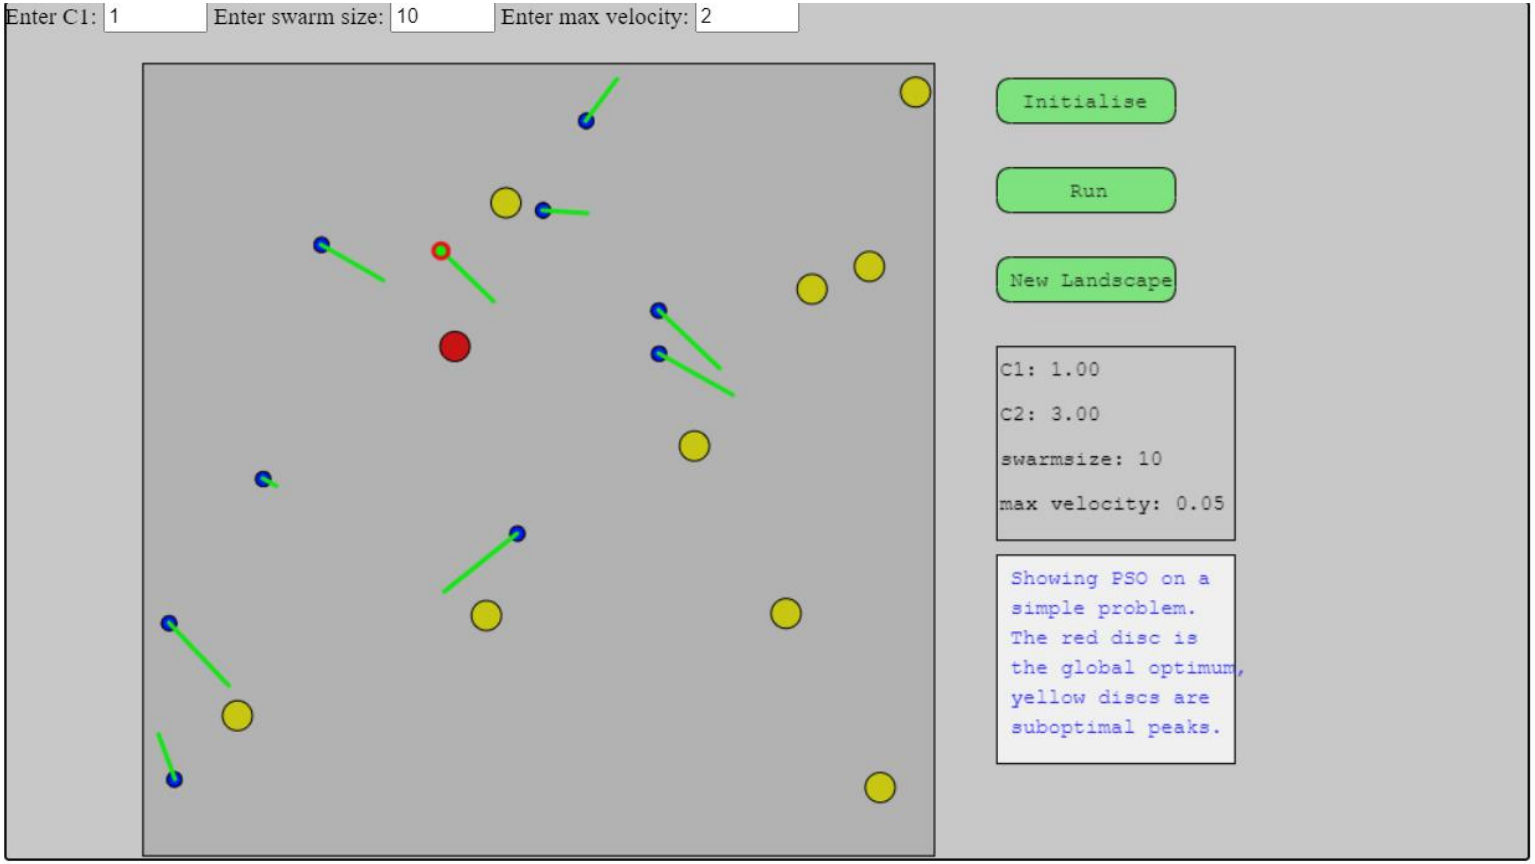

- EXEMPLO – Animação das partículas
  - http://www.macs.hw.ac.uk/~dwcorne/mypages/apps/pso.html

Otimização por Enxame de Partículas (PSO)

Edmarcio Belati

- PSO tradicional: As variáveis assumem valores contínuos.

- PSO binário: As variáveis assumem valores zero ou um.

- PSO seletivo: As variáveis assumem valores inteiros pré-selecionados.

  – Um algorítimo de PSO pode ser implementado para ter variáveis contínuas, binárias e inteiras.

Otimização por Enxame de Partículas (PSO)

Edmarcio Belati

Solução contínua (x;y).

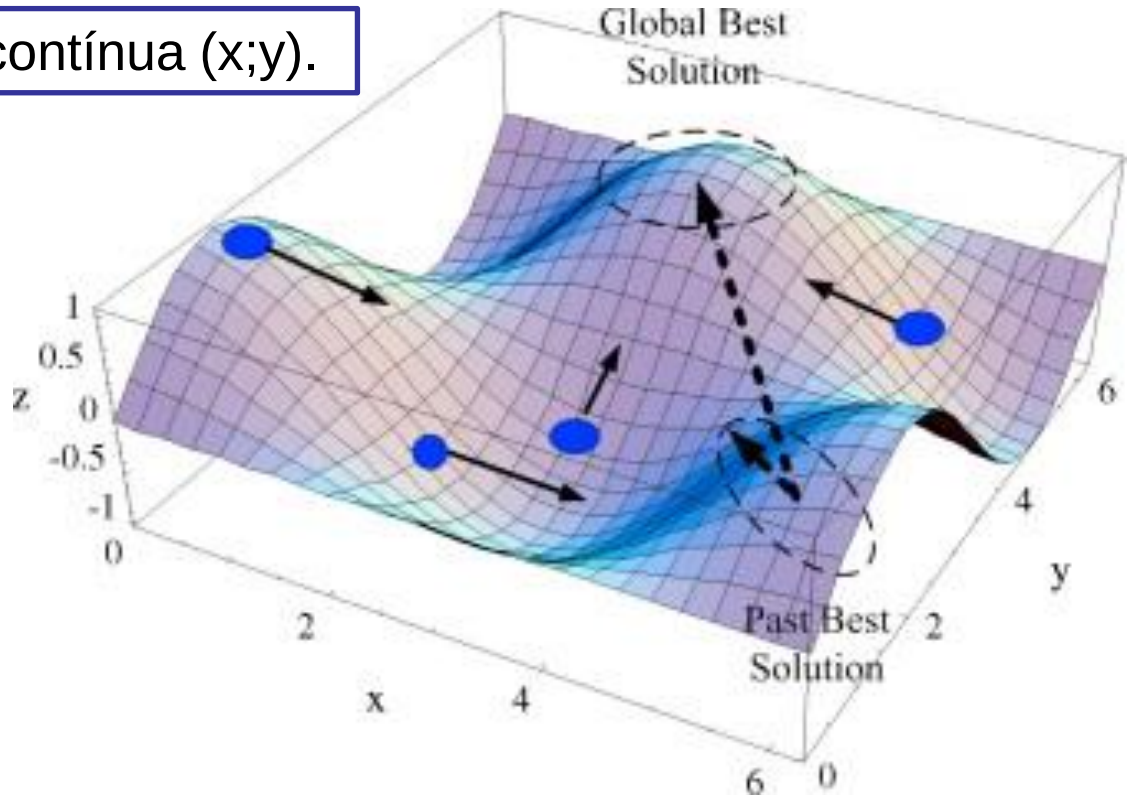

Figura 5 – comportamento de uma partícula

E se fosse necessário uma solução discreta ou binária?

PSO BINÁRIO: Formulação Matemática

No ano de 1997 os pesquisadores Kennedy e Eberhart , adaptaram o PSO a pesquisa em espaços binários, pela aplicação de uma transformação sigmoide com a componente da velocidade que comprimi as velocidades numa gama [0,1], fazendo com que as componentes das localizações das partículas assumissem um valor zero ou um.

$$sigmoide(V_i^{t+1}) = \frac{1}{1 + e^{-V_i^{t+1}}}$$

$$X_i^{t+1} = \begin{cases} 1, se\ rand < sigmoide(V_i^{t+1}) \\ 0, \quad se\ caso\ contrário \end{cases}$$

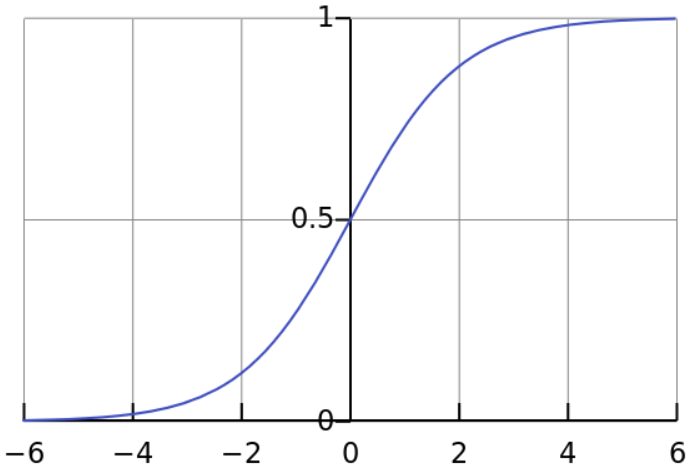

Função Sigmoide

PSO SELETIVO: Formulação Matemática

Baseado no PSO binário surgiu o PSO Seletivo. No PSO seletivo a posição de cada partícula passa de um ponto no espaço de valor real para **um ponto no espaço selecionado**.

A transformação sigmoide foi alterada, por Khalil e Gorpinich no 2012, para a equação (a) e a posição de cada partícula em uma dimensão *d* é um valor seletivo determinado pela equação (b).

$$sigmoide(V_i^{t+1}) = d_n \frac{1}{1+e^{-V_i^{t+1}}} \qquad S_d = [S_{d1}, S_{d2}, \dots, S_{dn}] \qquad \text{(a)}$$

$$X_i^{t+1} = \begin{cases} S_{d1}, & se\ sigmoide\left(V_i^{t+1}\right) < 1 \\ S_{d2}, & se\ sigmoide\left(V_i^{t+1}\right) < 2 \\ S_{d3}, & se\ sigmoide\left(V_i^{t+1}\right) < 3 \\ & \vdots \\ S_{dn}, & se\ sigmoide\left(V_i^{t+1}\right) < dn \end{cases} \qquad \text{(b)}$$

PSO – Artigo para estudar

T. M. Shami, A. A. El-Saleh, M. Alswaitti, Q. Al-Tashi, M. A. Summakieh and S. Mirjalili, "Particle Swarm Optimization: A Comprehensive Survey," in *IEEE Access*, vol. 10, pp. 10031-10061, 2022, doi: 10.1109/ACCESS.2022.3142859.

- **Abstract:**Particle swarm optimization (PSO) is one of the most well-regarded swarm-based algorithms in the literature. Although the original PSO has shown good optimization performance, it still severely suffers from premature convergence. As a result, many researchers have been modifying it resulting in a large number of PSO variants with either slightly or significantly better performance. Mainly, the standard PSO has been modified by four main strategies: modification of the PSO controlling parameters, hybridizing PSO with other well-known meta-heuristic algorithms such as genetic algorithm (GA) and differential evolution (DE), cooperation and multi-swarm techniques. This paper attempts to provide a comprehensive review of PSO, including the basic concepts of PSO, binary PSO, neighborhood topologies in PSO, recent and historical PSO variants, remarkable engineering applications of PSO, and its drawbacks. Moreover, this paper reviews recent studies that utilize PSO to solve feature selection problems. Finally, eight potential research directions that can help researchers further enhance the performance of PSO are provided.
- https://ieeexplore.ieee.org/stamp/stamp.jsp?tp=&arnumber=9680690

APLICAÇÃO

PSO

Algoritmo Geral - Estrutura

Edmarcio Belati

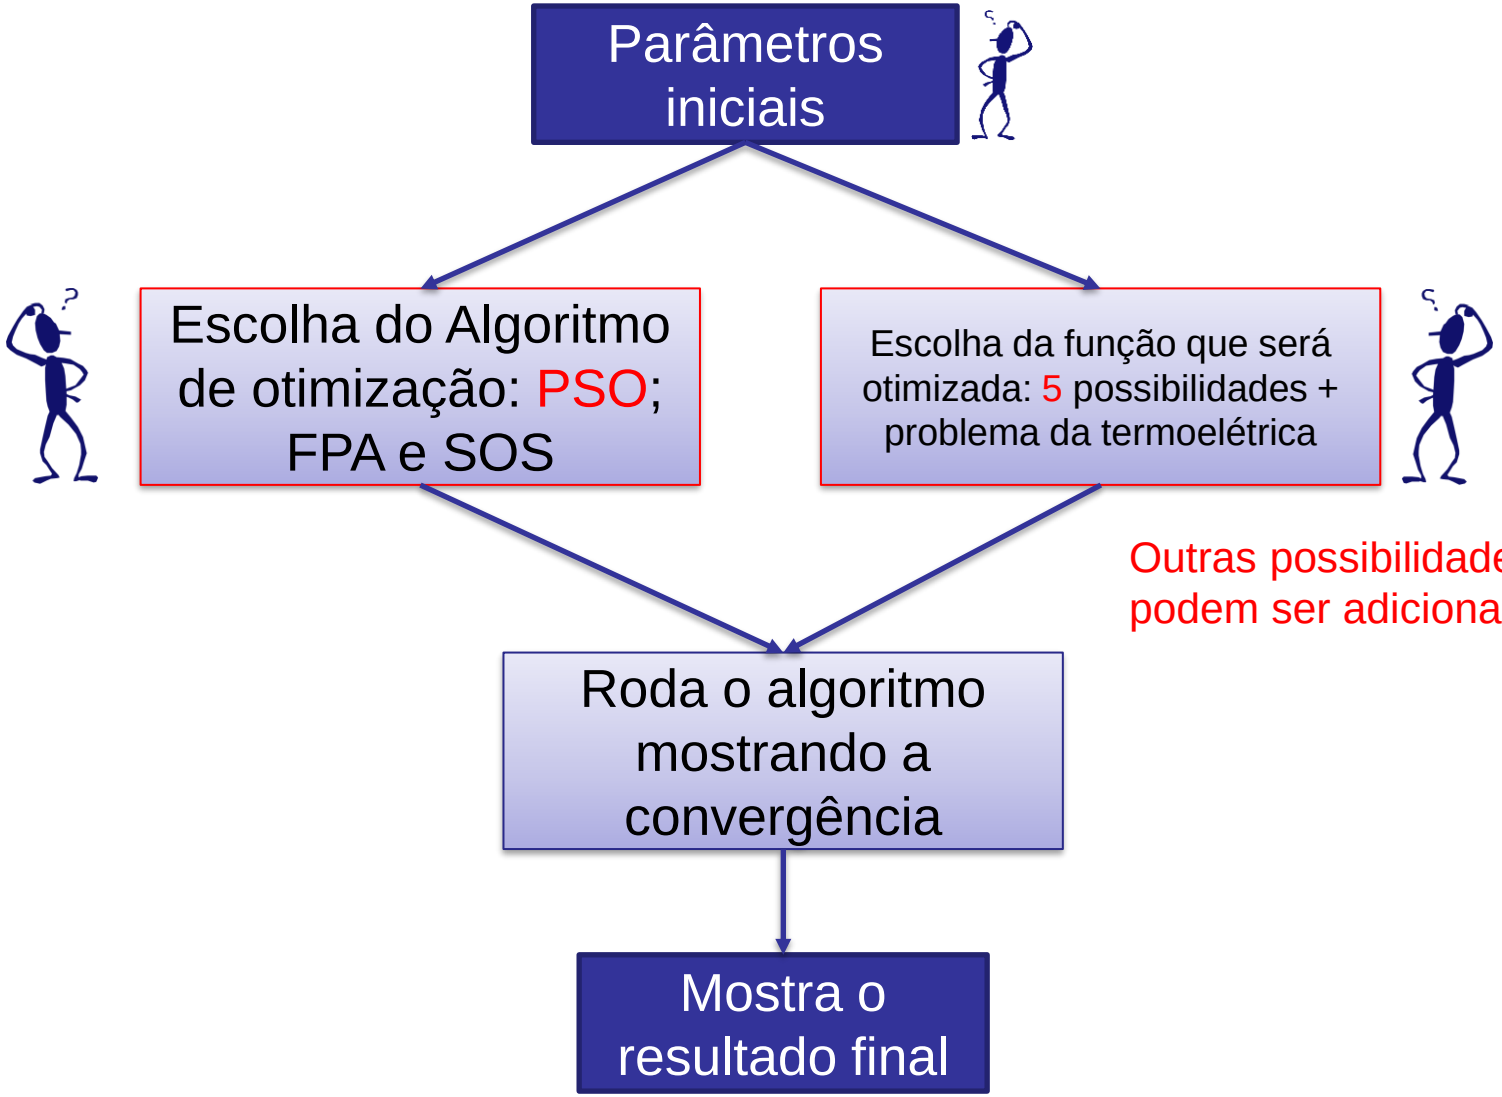

Funções para testes de algoritmos

Verificar matérial relacionado

Função quadrática de custo da termoelétrica

A representação básica de um gerador térmico pode ser aproximado por uma função quadrática, de acordo com a equação.

$$F_i = a_i + b_i PG_i + c_i PG_i^2$$

Os coeficientes *b* e *c* estão diretamente relacionado com a utilização do combustível. Já o coeficiente *a* representa o custo relacionado à mão-de-obra e à manutenção da termoelétrica.O PG está relacionado com a potência em W gerada pela termoelétrica.

Aplicação - Problema

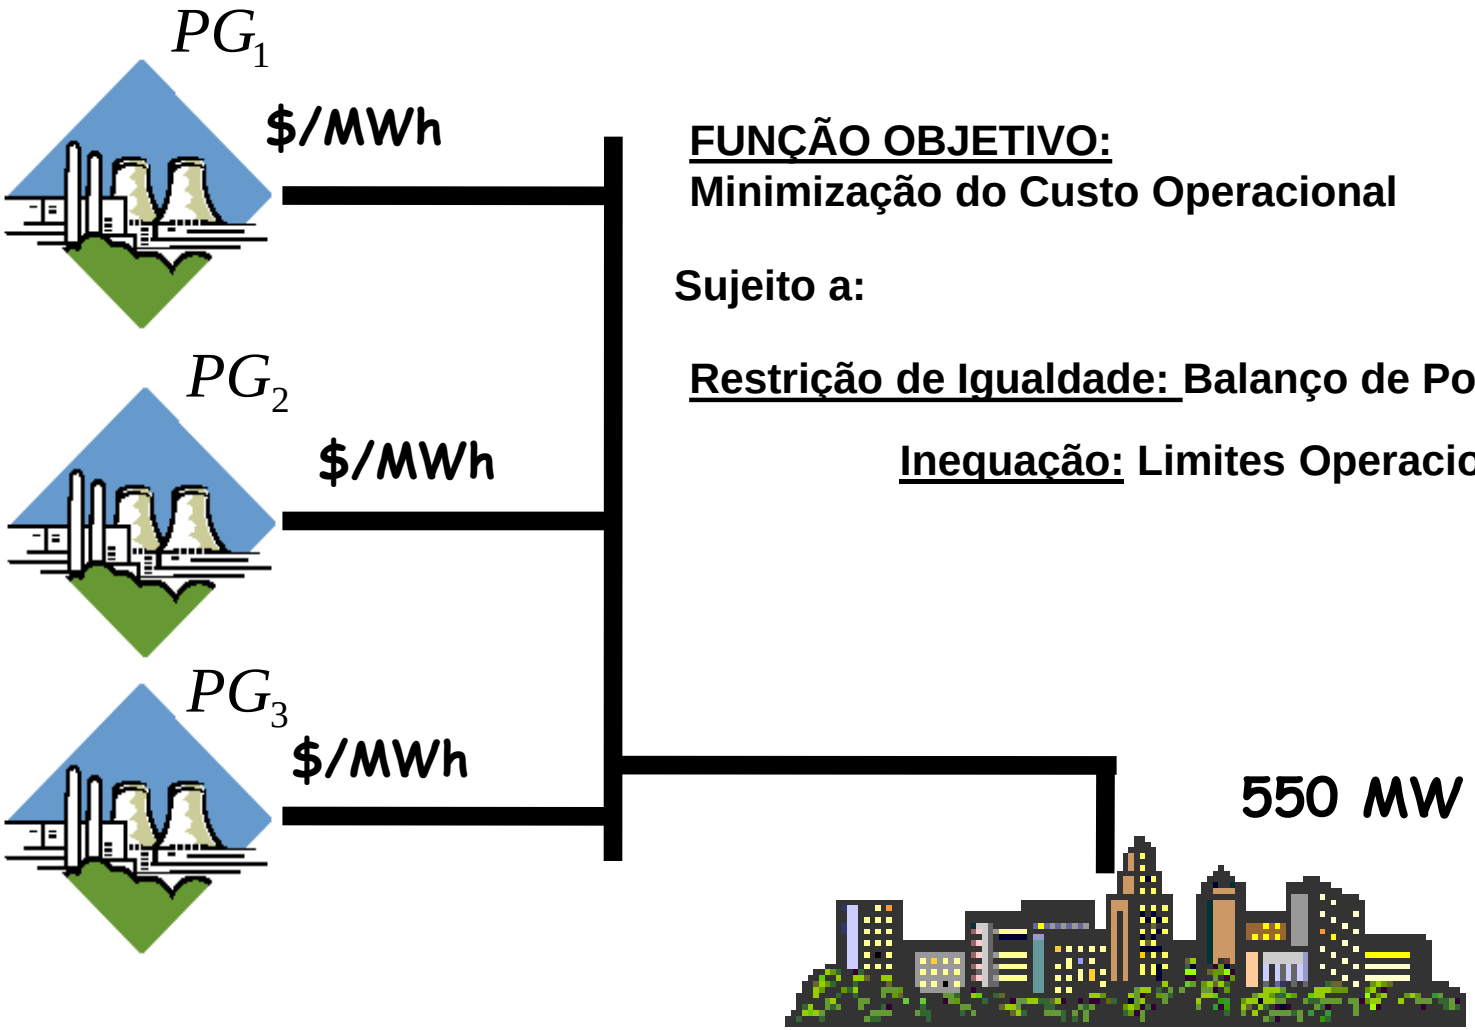

FUNÇÃO OBJETIVO:
Minimização do Custo Operacional

Sujeito a:

Restrição de Igualdade: **Balanço de Potência Ativa**

Inequação: **Limites Operacionais**

Dados da dos Geradores:

$$F_i = a_i + b_i PG_i + c_i PG_i^2$$

Termoelétrica	a $[\$/h]$	b $[\$/MWh]$	c $[\$/MW^2h]$	PG_{min} $[MW]$	PG_{max} $[MW]$
1	26,97	-0,3975	0,002176	100	226
2	1,865	-0,03988	0,001138	50	114
3	39,79	-0,3116	0,001457	200	332

A dimensão do problema é 3 ($PG_1, PG_2\ e\ PG_3$).

CUSTO de operação = $F_1 + F_2 + F_3$

FUNÇÃO OBJETIVO:
Minimização do Custo Operacional

Sujeito a:

Restrição de Igualdade: Balanço de Potência Ativa

Inequação: Limites Operacionais

$$
\begin{aligned}
& Minimizar \quad CUSTO \\
& s.a \\
& PG_1 + PG_2 + PG_3 = 550 \\
& 100 \leq PG_1 \leq 196 \\
& 50 \leq PG_2 \leq 114 \\
& 200 \leq PG_3 \leq 332
\end{aligned}
$$

Obter PG_1, PG_2, PG_3 e o CUSTO operacional.

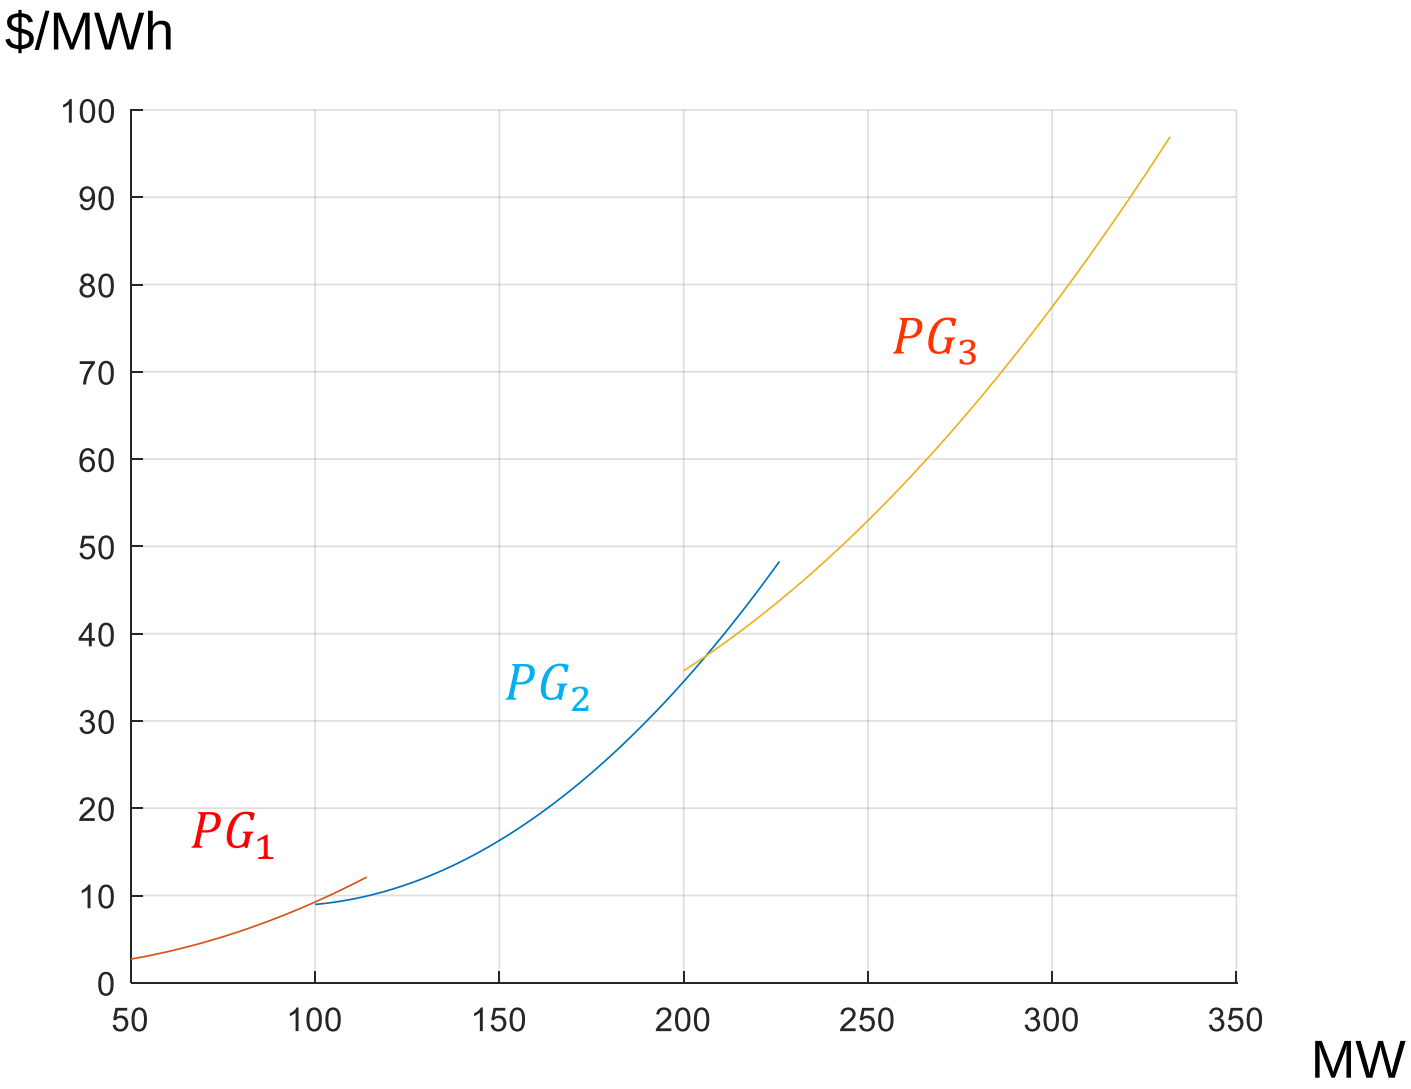
$/MWh
100
90
80
70
60
50
40
30
20
10
0
50
100
150
200
250
300
350
MW
PG_1
PG_2
PG_3

Dica para tratar a restrição e igualdade (transformar o problema restrito em irrestrito):

$(PG_1 + PG_2 + PG_3)$-550=0

$Min\ \ CUSTO + \alpha(PG_1 + PG_2 + PG_3)-550)^2$

α – fator penalidade (não pode ser muito pequeno, no entanto um valor muito alto pode comprometer o processo de otimização). Sugestão valores contidos em [10, 50]. O objetivo é atender a restrição de igualdade. Soma dos PGs=550 (verifica o valor após a convergência – objetivo é atender as restrições com o menor custo).

Obs. Existem técnicas específicas para transforma um problema restrito em irrestrito - pesquisar)

```
N=3;                    % Numer of dimension

X_max= [226,114,332];      % Boundary
X_min= [100,50,200];       % Boundary
```